

I Seminário de Extensão do Programa UFMS Digital



Estatística Descritiva no Software R

Trilha Temática IV – Ciência de Dados

Data: 31/05/2024

Dra. Magaly del Carmen Fonseca Medrano

magaly.fonseca@ufms.br

EaD
UFMS **DIGITAL**
Graduação

AGEAD
Agência de Educação
Digital e a Distância



Programação



1. Introdução ao R (30min)

- 1.1 Definições e Conceitos Técnicos de Programação
- 1.2 Apresentação geral do ambiente e Instalação
- 1.3 Noções de Sintaxe e Estrutura de funções
- 1.4 Comandos Básicos
- 1.5 Instalação de Pacotes

3. Estatística Descritiva (30min)

- 3.1 Medidas de Tendencia Central
- 3.2 Medidas de Variabilidade
- 3.3 Medidas de Posição
- 3.4 Layout de Gráficos

2. Manipulação de Dados com R (30min)

- 2.1 Tipos de Estrutura (Vetores, Data frames e Matrizes e Listas)
- 2.2 Importação e exportação de dados


1. Introdução ao R (30min)

- 1.1 Definições e Conceitos Técnicos de Programação
- 1.2 Apresentação geral do ambiente e Instalação
- 1.3 Noções de Sintaxe e Estrutura de funções
- 1.4 Comandos Básicos
- 1.5 Instalação de Pacotes



1.1 Definições e Conceitos Técnicos de Programação


Linguagem de programação interpretada – Alto



Powered by
bizagi
Modeler

1.1 Definições e Conceitos Técnicos de Programação

Linguagem de programação



Powered by
 bizagi
Modeler

1.1 Definições e Conceitos Técnicos de Programação

Aspecto	Linguagens Interpretadas	Avaliação	Linguagens Compiladas	Avaliação	Linguagens Híbridas	Avaliação
Disponibilidade de Código Fonte	Público	+	Privado	-	Público/Privado	+ -
Execução de processos	Execução mais lenta	-	Execução rápida	+	Lenta/Rápida	- +
Depuração de Código	Fácil depuração	+	Otimização geral	++	Fácil e Completa	+++
Compilação dos processos	Gera Bytecode	+	Gera Código de Máquina	-	Requer compilação em algumas partes	+ -
Portabilidade	Mais portátil, executado por uma máquina virtual.	+	Menos portátil, requer compilação específica para cada plataforma.	-	Portabilidade moderada, pode ser compilado ou interpretado	+ -
Segurança	O código-fonte é visível e pode ser facilmente inspecionado	-	O código de máquina é mais difícil de entender.	+	Nível de segurança variável	- +
Facilidade de Manutenção	Facil atualização e manutenção	+	Desafiador devido à necessidade de gerenciar diferentes versões compiladas	-	Flexibilidade de atualizações	+ -
Exemplos de Linguagens	R, Python, JavaScript, Ruby, PHP, etc.	3	C, C++, Go, Rust, Swift, etc.	0	Java, Kotlin, Scala, C,C++, etc.	3

1.1 Definições e Conceitos Técnicos de Programação

Desenvolvedores/Programadores

Linguagem de
Programação
Interpretada com
abordagem híbrida



- Criam pacotes R
- Possui habilidades avançadas em programação e conhecimento profundo da linguagem R
- Podem criar novas funções, algoritmos ou ferramentas, encapsulá-los em pacotes e disponibilizá-los para a comunidade R

Usuários

- Utilizam o R para análise de dados, estatísticas, visualizações e outras tarefas relacionadas
- Podem não ter uma formação em programação, mas estão familiarizados com a linguagem R

1.2 Apresentação Geral do Ambiente e Instalação

O que é o software R?

O **R** é uma linguagem e ambiente estatístico que traz muitas vantagens para o usuário, tais como: **(i) o R é um Software Livre** (livre no sentido de liberdade) distribuído sob a Licença Pública Geral, podendo ser livremente copiado, distribuído, e instalado em diversos computadores.; **(ii) os códigos-fontes R estão disponíveis para os usuários, e atualmente são gerenciados por um grupo chamado R Development Core Team**

O que é o software RStudio?

O **RStudio** é um ambiente de desenvolvimento de códigos em linguagem R. Ele funciona como uma espécie de interface, para utilizá-lo é necessário já possuir o R instalado em seu computador. A principal vantagem de se utilizar o RStudio é que ele permite que o usuário realize suas análises de maneira muito mais organizada e intuitiva.

RStudio

File Edit Code View Plots Session Build Debug Profile Tools Help

+ Go to file/function Addins

Figura 1.R x ← [Arquivo R]

```
1 #####
2 ##### Pontos críticos #####
3 ##### Logístico #####
4 #####
5
6 require(MASS)
7 require(lmtest)
8 require(car)
9
10 dados=read.table("dados.txt",header=T)
11 |
12 ##### valor inicial
13
14 plot(Ger~Dias,data=dados)
15 logi<-function(x,b0,b1,b2){
16   b0/(1+exp(b1-b2*x))
11:1 (Untitled) ♦
```

Console R Markdown

C:/Users/Lenovo/Desktop/Curso R/

> summary(log)

Formula: Ger ~ b0/(1 + exp(b1 - b2 * Dias))

Parameters:

	Estimate	Std. Error	t value	Pr(> t)
b0	51.3897	2.8939	17.758	<2e-16 ***
b1	6.1616	3.7323	1.651	0.1096
b2	1.8012	0.9784	1.841	0.0759 .

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 12.72 on 29 degrees of freedom

Number of iterations to convergence: 9

Achieved convergence tolerance: 4.31e-06

[Área de trabalho]

[Script]

[Console]

Run Source

Environment Connections


Import Dataset List

Global Environment

Data	32 obs. of 10 variables
dados	List of 6
log	List of 3
start	
values	
b0	880
b1	1.5
b2	0.19
Functions	
logi	function (x, b0, b1, b2)

History Files Plots Packages Help Viewer

Zoom Export



Instalação R/RStudio

EaD

AGEAD
Ucado
stânci



Google

r studio download



Todas

Vídeos

Imagens

Livros

Shopping

Mais

Ferramentas

Aproximadamente 2.020.000.000 resultados (0,27 segundos)



Posit

<https://posit.co/download/rstudio...> · Traduzir esta página

RStudio Desktop



1: Install R. **RStudio** requires R 3.3.0+. Choose a version of R that matches your computer's operating system. **Download** and install R. 2: Install **RStudio**. Find ...

[RStudio IDE](#) · [R Packages](#) · [Pricing](#) · [Cheatsheets](#)



Posit

<https://posit.co/downloads> · Traduzir esta página

Download RStudio

Download RStudio · Syntax highlighting, code completion, and smart indentation · Execute R code directly from the source editor · Quickly jump to function ...

Instalação R/RStudio



<https://posit.co/download/rstudio-desktop/>



PRODUCTS ▾ SOLUTIONS ▾ LEARN & SUPPORT ▾ EXPLORE MORE ▾ PRICING

1: Install R

RStudio requires R 3.3.0+. Choose a version of R that matches your computer's operating system.


[DOWNLOAD AND INSTALL R](#)

2: Install RStudio

[DOWNLOAD RSTUDIO DESKTOP FOR WINDOWS](#)

Size: 215.66 MB | [SHA-256: 93C7F307](#) | Version: 2023.12.0+369 | Released: 2024-01-10

Instalação R/RStudio



} **Instalar primeiro R
normal e posteriormente
RStudio e dar
continuidade ao
processo de instalação
dependendo do sistema:
Windows, Linux, Mac,
etc.**

Arquivos

Os R gera alguns tipos de arquivos que podem ser salvos. Os principais são:

- **.R** - Usado para salvar códigos criados e rotinas de análises (*scripts*)
- **RData** - Usado para salvar os objetos da área de trabalho (*workspace*)
- **Rhistory** - Usado para salvar o histórico dos comandos executados (normalmente salvo automaticamente).
- **Rproj** - Guarda informações sobre projetos

Nome	Data de modificação
.Rhistory	31/01/2024 12:18
TesteProjetoNovo	31/01/2024 12:14
testescript	31/01/2024 11:59
testescript2	31/01/2024 11:59

Nome	Data de modificação
TesteProjetoNovo	31/01/2024 12:14
ApresentaçõExemplos	26/01/2024 18:38
clima	26/01/2024 17:50
Aula1	26/01/2024 18:34
.RData	26/01/2024 18:39
.Rhistory	31/01/2024 11:54
Ementa do Curso Básico e Introdutório d...	25/01/2024 16:40
carros	25/01/2024 18:13
pratica1	26/01/2024 14:01

1.3 Noções de Sintaxe e Estrutura de Funções

- Adicionar comentário

? - Obter ajuda de função

?? - Realizar buscar

<- ou = - Atribuir objeto (direita para esquerda)

-> - Atribuir objeto (esquerda para direita)

+ - Somar

- - Subtrair

* - Multiplicar

/ - Dividir

^ - Potencializar (direita para esquerda)

%*% - Multiplicar matrizes

< - Comparar, menor

> - Comparar, maior

<= - Comparar, menor ou igual

>= - Comparar, maior ou igual

== - Comparar, exatamente igual

!= - Comparar, diferente

& - Lógico, critério aditivo E. Operação elementar

| - Lógico, critério aditivo OU. Operação elementar

&& - Lógico, E

|| - Lógico, OU

~ - Fórmula estatística

FALSE ou F - Argumento lógico falso

TRUE ou T - Argumento lógico verdadeiro

NA - Indeterminado (Not Available)

NaN - Indeterminado (Not a Number)

Inf - Infinito

NULL - Objeto nulo

c() - Concatenar valores em vetor

factor() - Criar fator

ordered() - Criar fator ordenado

data.frame() - Criar tabela de dados (data.frames)

matrix() - Criar matriz

list() - Criar lista

1.3 Noções de Sintaxe e Estrutura de Funções

Calculadora

2+2 # Soma

[1] 4

8-3 # Subtração

[1] 5

3*8 # Multiplicação

[1] 24

8/2 # Divisão

[1] 4

2^8 # Potências

[1] 256

(2+4)/7 # Prioridade de solução

[1] 0.8571429

Shortcuts

<Ctrl>+<Enter> = Run → Rodar Script

<Ctrl>+<L> → Limpa a área do console

Ordem de parêntesis:

1-()

2-{}
3-[] é usado em vetores

Fazer ao vivo

1.3 Noções de Sintaxe e Estrutura de Funções



Funções

Função
(argumento1=valor1,argumento2=valor2)

Tipos de Funções

1. Operações Aritméticas
2. Atribuição de Variáveis
3. Vetores e Indexação
4. Estatística Básica
5. Estrutura de Controle de Fluxo

1.3 Noções de Sintaxe e Estrutura de Funções

Funções de Operações Aritméticas

```
# Soma  
resultado_soma <- 5 + 4  
print(resultado_soma) # Resultado: 9  
  
# Raiz quadrada  
sqrt(9)  
# Resultado: 3  
  
# Logaritmos  
log10(100)  
# Resultado: 2  
  
# Divisão  
resultado_divisao <- 20 / 5  
print(resultado_divisao) # Resultado: 4
```

Funções de Atribuição de Variáveis

```
# Atribuição de variáveis  
meu_numero <- 15  
meu_texto <- "Olá, Mundo!"  
  
print(meu_numero)  
print(meu_texto)
```

Funções de Vetores e Indexação

```
# Criar um vetor  
meu_vetor <- c(2, 4, 6, 8, 10)  
  
# Acessar elementos do vetor  
elemento_terceiro <- meu_vetor[3]  
print(elemento_terceiro) # Resultado: 6
```

1.3 Noções de Sintaxe e Estrutura de Funções

Funções de Estatística Básica

```
# Calcular a média  
vetor_media <- mean(meu_vetor)  
print(vetor_media)  
  
# Calcular o desvio padrão  
vetor_desvio_padrao <- sd(meu_vetor)  
print(vetor_desvio_padrao)
```

Estrutura de Controle de Fluxo

```
# Estrutura condicional (if-else)  
idade <- 20  
  
if (idade >= 18) {  
  print("Você é maior de idade.")  
} else {  
  print("Você é menor de idade.")  
}
```

Porque é importante usar ou criar funções?

Compactar grupo de comandos e fazer o processo da análise mais rápida e eficiente

1.4 Comandos Básicos

`getwd()` # Mostrar o diretório de trabalho atual

RStudio interface showing the code `getwd()` in the script editor. The console below shows the output:

```
R 4.3.2 - C:/Users/Maggie/Desktop/AulaBasicaR/TesteProjetoNovo/
> getwd()
[1] "C:/Users/Maggie/Desktop/AulaBasicaR/TesteProjetoNovo"
>
```

`dir()` # Listar os arquivos do diretório

RStudio interface showing the code `dir()` in the script editor. The console below shows the output:

```
R 4.3.2 - C:/Users/Maggie/Desktop/AulaBasicaR/TesteProjetoNovo/
> dir()
[1] "TesteProjetoNovo.Rproj" "testescript.R"      "testescript2.R"
>
```

`setwd()` # Mudar o diretório de trabalho

```
1 getwd
2 setwd("C:/Users/Maggie/Desktop/AulaBasicaR")
3
```

3:1 (Top Level) ↴


Console Terminal × Background Jobs ×

R 4.3.2 - C:/Users/Maggie/Desktop/AulaBasicaR/ ↵

```
> dir()
[1] "TesteProjetoNovo.Rproj" "testescript.R"           "testescript2.R"
> getwd()
[1] "C:/Users/Maggie/Desktop/AulaBasicaR/TesteProjetoNovo"
> setwd("C:/Users/Maggie/Desktop/AulaBasicaR")
> C:/Users/Maggie/Desktop/AulaBasicaR/TesteProjetoNovo|
```

1.5 Instalação de Pacotes




Os pacotes do R podem ser extraídos de vários repositórios:



```
1
2 Install.packages("devtools")
```

Pode digitar o comando `install.packages` + o nome do pacote
ou

Instalá-lo desde a aba “Tools”




1.5 Instalação de Pacotes



<https://www.bioconductor.org/>

2. BIOCONDUCTOR



The screenshot shows the homepage of the Bioconductor website. At the top, there is a green header bar with the text "Welcome to the new bioconductor.org!" and a small triangle icon. Below the header, the Bioconductor logo is displayed, consisting of a stylized green and blue musical note-like shape followed by the text "Bioconductor" and "OPEN SOURCE SOFTWARE FOR BIOINFORMATICS". To the right of the logo are navigation links for "About", "Learn", "Packages", and "Developers", along with a search bar and a "Get Started >" button. The main content area features a large, bold title: "Open source software for Bioinformatics" with "Bioinformatics" in green. Below the title, a subtitle reads: "The Bioconductor project aims to develop and share open source software for precise and repeatable analysis of biological data. We foster an inclusive and collaborative community of developers and data scientists." At the bottom of the main content area is another "Get started >" button.

3. GITHUB

<https://github.com/>

The screenshot shows the GitHub Home page. On the left, there's a sidebar with 'Top Repositories' (including TiagoOlivoto/tiagoolivoto, AndriSignorelli/DescTools, mfm2174/mfm2174, OpenDroneMap/FIELDImageR, TiagoOlivoto/pliman, r-spatial/mapedit) and 'Recent activity'. The main area has a search bar at the top right. A central box displays 'Updates to your homepage feed' with a message about combining Following and For you feeds. Below it are sections for 'Start writing code', 'Start a new repository for mfm2174', and 'Repositories that need your help' (listing tcurd / jdeb). To the right, a 'Latest changes' sidebar lists recent updates from the GitHub team.

Dashboard

Top Repositories

New

Find a repository...

TiagoOlivoto/tiagoolivoto

AndriSignorelli/DescTools

mfm2174/mfm2174

OpenDroneMap/FIELDImageR

TiagoOlivoto/pliman

r-spatial/mapedit

Recent activity

When you take actions across GitHub, we'll provide links to that activity here.

Home

Send feedback

Filter 8

Updates to your homepage feed

We've combined the power of the Following feed with the For you feed so there's one place to discover content on GitHub. There's improved filtering so you can customize your feed exactly how you like it, and a shiny new visual design. 🎉

Learn more

Start writing code

Start a new repository for mfm2174

A repository contains all of your project's files, revision history, and collaborator discussion.

Repositories that need your help

tcurd / jdeb

This library provides an Ant task and a Maven plugin to create Debian packages from Java builds in a truly cross-platform manner.

Latest changes

5 hours ago

CodeQL for Visual Studio Code documentation is now on...

20 hours ago

Updates to GitHub Importer and the deprecation of the Source Import REST...

Yesterday

Configure organization-level CodeQL model packs for GitHub code scanning

2 days ago

GitHub Enterprise Importer's new git source migrator improves reliability of...

View changelog →

2. Estrutura e Manipulação de Dados (30min)

**2.1 Tipos de Estrutura (Vetores, Data frames,
Matrizes e Listas)**

2.2 Importação e Exportação de Dados



2.1 Tipos de Estruturas

Vetores (vector)

São estruturas de dados fundamentais que **armazenam elementos do mesmo tipo**. Eles podem ser **numéricos, caracteres, lógicos e data**

numeros <- c(5,4,3,2,1)
nomes <- c("Alice", "Bob", "Charlie")
logico <- c(TRUE, FALSE, TRUE)
datas <- as.Date(c("2022-01-01", "2022-02-01"))

Fatores

É um vetor que representa **dados categóricos**

```
genero <- factor(c("Masculino", "Feminino", "Masculino", "Feminino"))
```

```
avaliacao <- factor(c("Ruim", "Regular", "Bom", "Excelente"))
```

Indexar Vetores

```
numeros[4]  
[1] 2
```

Acessa o 4to valor

```
numeros[c(1,3,5)]  
[1] 5,3,1
```

Acessa o 1er, 3ero e 5to valor

Data frames (Tabelas)



Um data frame é uma estrutura bidimensional que organiza dados em linhas e colunas, semelhante a uma planilha. Cada coluna pode conter diferentes tipos de dados, mas todas as colunas devem ter o mesmo número de linhas

```
nomes<-  
c("ARTUR","ROBERTO","HELCI","NATALIA","LANA","ROGERIO","E  
LAINE","JAIRO","LETICIA")
```

```
genero<-c("M", "M", "M", "F", "F", "M", "F", "M", "F")
```

```
faixaecom<-c("A", "B", "C", "A ", "B", "C", "D", "A", "D")
```

```
avaliacao<-c("excelente", "bom", "bom", "ruim", "pessimo", "regular",  
"regular", "mbom", "bom")
```

```
filhos<-c("TRUE", "FALSE", "TRUE", "FALSE", "FALSE", "FALSE",  
"TRUE", "TRUE", "TRUE")
```

```
meu.df<-data.frame(nomes,genero,faixaecom,avaliacao,filhos)
```

Fonte: Carvalho(2024)

Professora Dra. Magaly del Carmen Fonseca Medrano



NOME	GENERO	FAIXAECON	AVALIACAO	FILHOS
ARTUR	M	A	EXCELENTE	TRUE
ROBERTO	M	B	BOM	FALSE
HELCI	M	C	BOM	TRUE
NATALIA	F	A	RUIM	FALSE
LANA	F	B	PESSIMO	FALSE
ROGERIO	M	C	REGULAR	FALSE
ELAINE	F	D	REGULAR	TRUE
JAIRO	M	A	MBOM	TRUE
LETICIA	F	D	BOM	TRUE

Fazer ao vivo

Matrizes



Uma matriz assim como o *data frame* é uma **estrutura bidimensional que organiza dados em linhas e colunas. Todos os elementos contidos devem ser do mesmo tipo**

n

m

Modelagem feminina					
Tamanho / Estampa	lisa	flores	dragão	pirata	
P	10	5	0	16	
M	15	12	10	14	
G	12	7	16	11	

Modelagem masculina					
Tamanho / Estampa	lisa	flores	dragão	pirata	
P	8	4	8	12	
M	7	13	10	20	
G	15	8	16	2	



$$A_1 = \begin{pmatrix} 10 & 5 & 0 & 16 \\ 15 & 12 & 10 & 14 \\ 12 & 7 & 16 & 11 \end{pmatrix}$$


A1, $a_{12}=5$

Fila1, Coluna2



$$A_2 = \begin{pmatrix} 8 & 4 & 8 & 12 \\ 7 & 13 & 10 & 20 \\ 15 & 8 & 16 & 2 \end{pmatrix}$$

Matrizes



Fonte: ENEM(2024)

Professora Dra. Magaly del Carmen Fonseca Medrano

OPINION



AGEAD
Agência de Educação
Digital e a Distância



→ A figura desenhada pelo código binário, utilizado em informática, é uma matriz

Matrizes

```
matriz_numerica <- matrix(c(1, 2, 3, 4, 5, 6), nrow = 2, ncol = 3, byrow = TRUE)  
print(matriz_numerica)
```



Matriz 2x3

```
[,1] [,2] [,3]  
[1,] 1 2 3  
[2,] 4 5 6
```

```
6 head(matriz_numerica, n=1)  
7  
5:1 (Top Level) ⇡  
Console Terminal × Background Jobs ×  
R 4.3.2 · C:/Users/Maggie/Desktop/AulaBasicaR/  
> head(matriz_numerica, n=1)  
[,1] [,2] [,3]  
[1,] 1 2 3
```

Mostra os
dados da fila 1

```
8 tail(matriz_numerica,n=1)  
9  
10  
9:1 (Top Level) ⇡  
Console Terminal × Background Jobs ×  
R 4.3.2 · C:/Users/Maggie/Desktop/AulaBasicaR/  
> tail(matriz_numerica,n=1)  
[,1] [,2] [,3]  
[2,] 4 5 6
```

Mostra os
dados da última
fila

Matrizes

```
4 str(matriz_numerica)
5
```

4:21 | (Top Level) ⇣

Console Terminal × Background Jobs ×

```
R 4.3.2 · C:/Users/Maggie/Desktop/AulaBasicaR/
> str(matriz_numerica)
num [1:2, 1:3] 1 4 2 5 3 6
>
```



Mostra o resumo da matriz
1:2 -> 2 filas
1:3-> 3 colunas

```
7 nrow(matriz_numerica)
8
9
```

8:1 | (Top Level) ⇣

Console Terminal × Background Jobs ×

```
R 4.3.2 · C:/Users/Maggie/Desktop/AulaBasicaR/
> nrow(matriz_numerica)
[1] 2
>
```



Mostra o # de filas

```
7 ncol(matriz_numerica)
8
9
```

8:1 | (Top Level) ⇣

Console Terminal × Background Jobs ×

```
R 4.3.2 · C:/Users/Maggie/Desktop/AulaBasicaR/
> ncol(matriz_numerica)
[1] 3
```



Mostra o # de colunas

Matrizes

matriz_numerica[1,1]
[1] 1




Mostra o conteúdo da
fila1,coluna1

Indexar Matrizes

[,1]	[,2]	[,3]
[1,]	1	2
[2,]	4	5

matriz_numerica[-2, , drop = FALSE]
[,1] [,2] [,3]
[1] 1 2 3



Se está excluindo a segunda linha da matriz

drop = FALSE: é usado para garantir que o resultado seja uma matriz (e não um vetor) mesmo que tenhamos apenas uma linha após a exclusão da segunda linha

matriz_numerica <- matriz_numerica[,c(2,1,3)]



Está alterando a ordem das primeiras 2 colunas

```
> print(matriz_numerica)  
 [,1] [,2] [,3]  
[1,] 2 1 3  
[2,] 5 4 6
```

Listas



Podem conter **elementos de diferentes tipos e ser multidimensionais**

```
# Criando um vetor  
vetor_numerico <- c(1, 2, 3, 4, 5)
```

```
# Criando uma matriz  
matriz_numerica <- matrix(1:6, nrow = 2, ncol = 3)
```

```
# Criando um data frame
```

```
dataframe_exemplo <- data.frame(  
  Nome = c("Alice", "Bob", "Charlie"),  
  Idade = c(25, 30, 22),  
  Salario = c(50000, 60000, 45000)  
)
```

```
# Criando uma lista que contém o vetor, a matriz, e o data  
frame
```

```
minha_lista <- list(  
  Vetor = vetor_numerico,  
  Matriz = matriz_numerica,  
  DataFrame = dataframe_exemplo,  
  OutroElemento = "Texto de exemplo",  
  Logico = TRUE )
```

```
# Exibindo a lista  
print(minha_lista)
```

Listas

Indexar Listas

\$



É usado para acessar elementos de uma lista ou de um data frame no R

```
30 minha_lista$Matriz
31 |
32
31:1 (Top Level) ⇣
Console Terminal × Background Jobs ×
R 4.3.2 - C:/Users/Maggie/Desktop/AulaBasicaR/
> minha_lista$Matriz
 [,1] [,2] [,3]
[1,] 1 3 5
[2,] 2 4 6
```

```
30 minha_lista$DataFrame
31 |
32
31:1 (Top Level) ⇣
Console Terminal × Background Jobs ×
R 4.3.2 - C:/Users/Maggie/Desktop/AulaBasicaR/
> minha_lista$DataFrame
  Nome Idade salario
1 Alice 25 50000
2 Bob 30 60000
3 charlie 22 45000
```

minha_lista[2] → Mostra o conteúdo da Matriz (Sublista)

minha_lista[[2]] → Dá acesso ao conteúdo da Matriz

print(sum(minha_lista[[2]])) #soma todos os elementos da Matriz=21

minha_lista[3]

minha_lista[[3]]

2.2 Importação e Exportação de Dados

Importação

Existem diversas maneira para abrir um arquivo que contém dados:

Arquivos extensão csv

```
dados<-read.csv("nomearquivo.csv", header=TRUE, ...)  
dados<-read.csv(file.choose())  
dados<-read.csv("C:/Users/Maggie/Desktop/AulaR/nomedoarquivo.csv")
```

Arquivos extensão xls

Precisa-se instalar o pacote readxl
dados<-read_excel(caminho_do_arquivo) ou
dados<-read_excel(caminho_do_arquivo, sheet=2)

```
dados<-read_excel(file.choose())  
dados<-read_excel("C:/Users/Maggie/Desktop/AulaBasicaR/nomedoarquivo.xlsx")
```

2.2 Importação e Exportação de Dados

Importação

LER DADOS CSV

```
library(readr)  
  
clima <- read.csv("clima.csv", header = TRUE)  
clima=read.csv(file.choose())  
clima=read.csv("C:/Users/Maggie/Desktop/AulaBasicaR/clima.csv")
```

LER DADOS DE EXCEL

```
library(readxl)  
  
carros<-read_excel("C:/Users/Maggie/Desktop/AulaBasicaR/carros.xlsx")  
Carros<-read_excel(file.choose())  
carros<-read_excel("C:/Users/Maggie/Desktop/AulaBasicaR/nomedoarquivo.xlsx")
```

2.2 Importação e Exportação de Dados

Exportação

```
library(readxl)  
  
carros<-read_excel("C:/Users/Maggie/Desktop/AulaBasicaR/carros.xlsx")
```

1) Função Export

```
library(rio)  
  
export(carros, file="C:/Users/Maggie/Desktop/AulaBasicaR/carrosteste1.txt")
```


2) Função Write.Table / Write.csv (data frames)

```
write.table(carros,"C:/Users/Maggie/Desktop/AulaBasicaR/carrosteste2.txt" )  
  
write.csv(carros,"C:/Users/Maggie/Desktop/AulaBasicaR/carrosteste3.csv")
```

3. Estatística Descritiva (30min)

- 3.1 Medidas de Tendência Central (Média, Mediana, Moda)
- 3.2 Medidas de Variabilidade (Variância, Desv.Padrão, Coef. Variação)
- 3.3 Medidas de Posições (Percentis e Quartis)
- 3.4 Tipos de Gráficos

Tipos de Estatística



Fonte: Aguado(2023);Beneti(2011);
Castañeda(2016); Hair et al.(2009);
Kopczewska(2020); Piegorsch et al.(2022);
Silvestre, A.(n.d.)

Análises aplicáveis na estatística descritiva:

3.1 Medidas de centralidade: Média, mediana, moda

3.2 Medidas de variabilidade: Variância, desvio padrão, coeficiente de variação

3.3 Medidas de posições: quartis e percentis

3.1 Medidas de Centralidade: Média, Mediana e Moda

```
clima <- read.csv("clima.csv", header = TRUE)
```

```
# Calcular a média
```

```
media <- mean(clima$tmax)
```

```
# Calcular a mediana
```

```
mediana <- median(clima$tmax)
```

A **média (M_e)** é calculada somando-se todos os valores de um conjunto de dados e dividindo-se pelo número de elementos deste conjunto.

A **Mediana (M_d)** representa o **valor central** de um conjunto de dados

3.1 Medidas de Centralidade: Média, Mediana e Moda

A Moda (M_o) representa o **valor mais frequente** de um conjunto de dados

1) *## criando uma série de dados qualquer*

```
w <- c(1, 2, 3, 4, 4, 4, 5, 6, 7)
```

visualmente encontrando a moda da série

```
table (w)
```

```
## w
```

```
## 1 2 3 4 5 6 7
```

```
## 1 1 1 3 1 1 1
```

2) *# Calcular a moda*
#1era opção - menos elaborada
moda<-table(clima\$tmax)
print(modal)

#2da opção - mais elaborada
moda <- names(sort(-table(clima\$tmax)))[1]
print(modal)



Arquivo clima.csv

3.2 Medidas de Variabilidade: Variância, Desvio Padrão e Coeficiente de Variação

O que variância? é uma medida de dispersão que indica o quanto distantes os valores estão da média

Mais difícil de interpretar diretamente, pois está em unidades quadradas

Variância Populacional

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

Onde,

σ^2 : variância

x_i : valor analisado

\bar{x} : média aritmética do conjunto

n : número de dados do conjunto

Variância Amostral

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - 1}$$

s^2 : variância

Desvio Padrão

$$DP = \sqrt{\sigma^2} \text{ ou } DP = \sqrt{s^2}$$

É a raiz quadrada da variância e fornece uma medida de dispersão em torno da média

3.2 Medidas de Variabilidade: Variância, Desvio Padrão e Coeficiente de Variação

Exemplo:

Se a altura de um grupo de pessoas tem uma variância de 64 cm quadrados ($\sigma^2=64\text{cm}^2$), significa que em média, os dados estão a 8cm ($\sigma=8\text{cm}$) (Desvio Padrão) da média.

Coeficiente de Variação

Indica a variabilidade de dispersão dos dados com respeito à média em %

```
# Calcular a variância  
variancia <- var(clima$tmax)
```

3.54792634615385

```
# calcular o desvio padrão  
desvio_padrao <- sd(clima$tmax)
```

1.88359399716442

```
# calcular o coeficiente de variação  
coef_variacao <- desvio_padrao / mean(clima$tmax) * 100
```

7.1374045293572

Interpretação do Coef.Variação: o desvio padrão dos valores de temperatura máxima é cerca de 7.13%

3.2 Medidas de Variabilidade: Variância, Desvio Padrão e Coeficiente de Variação

```
##### RESUMIR DADOS COM GROUP_BY e SUMMARISE #####
# Serve para observar a dispersão dos pontos em relação
# à média ou a uma linha de tendência

library(readr)
library(dplyr)    #filtragem, agrupação, agregação
library(lubridate) #lida com datas e tempos
library(ggplot2)  #gráficos

dado<-read_csv("clima.csv")%>%group_by()
dado<-read_csv("clima.csv")%>%group_by(month(data)) #cria coluna do mês (só o número)
dado<-read_csv("clima.csv")%>%group_by(mes=month(data)) #nomea coluna como: mes
dado<-read_csv("clima.csv")%>%group_by(mes=month(data,label=TRUE)) #coloca nome do mês no
#lugar de números

dado<-read_csv("clima.csv")%>%
  group_by(mes=month(data,label=TRUE))%>%
  summarise(media=mean(tmax))

dado<-read_csv("clima.csv")%>%
  group_by(mes=month(data,label=TRUE))%>%
  summarise(media=mean(tmax),desv.pad=sd(tmax))
```

3.2 Medidas de Variabilidade: Variância, Desvio Padrão e Coeficiente de Variação

```
##### Gráfico de Dispersão/Histograma para ver variação com respeito à Média
```

```
#Média: 26.39
```

```
# Gráfico de Dispersão (Deve-se Especificar eixo x,y)
ggplot(dado, aes(x=media,y=desv.pad))+geom_point()
```

```
# Gráfico de Histograma
ggplot(dado, aes(x=media,y=desv.pad))+geom_col() #Histograma
```

3.3 Medidas de Posições

Quartis e Percentis

Conjunto de Dados:

12, 18, 22, 25, 28, 30, 35, 40, 45, 50



$$(28+30)/2=29 \rightarrow \text{Mediana}$$


Quartis:

Primeiro Quartil (Q1): É o valor que deixa 25% dos dados abaixo e 75% acima. Também é conhecido como o 25º percentil.

Segundo Quartil (Q2): É a mediana, representando o valor que divide os dados ao meio (50% abaixo e 50% acima). Também é conhecido como o 50º percentil.

Terceiro Quartil (Q3): É o valor que deixa 75% dos dados abaixo e 25% acima. Também é conhecido como o 75º percentil.

Um quantil é um conceito estatístico que divide um conjunto de dados ordenados em partes iguais ou em porcentagens específicas. Descrevem a posição relativa de um valor dentro desse conjunto de dados.



3.3 Medidas de Posições

Quartis e Percentis

```
# Quantis & Percentis
dados <- c(12, 18, 22, 25, 28, 30, 35, 40, 45, 50)

# calcular os quantis teóricos
quantis_teóricos <- quantile(dados, probs = seq(0.25, 0.75, 0.01)) #25%, 75%, 0.01=compasso

#Determinar a distribuição dos quantis
quantile(dados)
```

3.3 Medidas de Posições

Quartis e Percentis

GRÁFICO DE QUANTIS & PERCENTIS



Também conhecido como Q-Q plot, é uma ferramenta gráfica útil para comparar duas distribuições de probabilidade

```
qqplot(quantis_teóricos, dados,  
       xlab = "Quantis teóricos",  
       ylab = "Dados",  
       main = "Gráfico Q-Q de quantis e percentis")
```

```
abline(0, 1, col = "red") # Adiciona linha de referência no eixo Y=0,1=45 graus
```

GRÁFICO Determinar a normalidade dos quantis

```
qqnorm(dados) #Quantidades Teoricas oscila entre -3 a 3 (Distribuição Normal)  
qqline(dados) #Linha de referência da distribuição normal
```

3.4 Medidas de Centralidade-GRÁFICOS

HISTOGRAMA

Visualiza a distribuição de dados quantitativos, forma de distribuição, identifica outliers, etc.

```
hist(clima$tmax)

# Modificar info eixo x e y
hist(clima$tmax, main = "Histograma", xlab = "Valores", ylab = "Frequência",
     col = "lightblue", border = "black")

# Adicionar legenda
legend("topright", legend = c("Percentis & Quantis"), fill = "lightblue", border = "black")
```

3.4 Medidas de Centralidade-GRÁFICOS

BARPLOT

Visualiza **dados categóricos**, Compara frequências, identifica padrões e tendências



Dados que representam categorias (gênero, país) ou grupos discretos (absolutos)

```
library(readxl)

salarios<-read_excel('salarios.xlsx',3)

barplot(salarios$RENDAMENSAL)

#Adicionando títulos e cor
barplot(salarios$RENDAMENSAL, names.arg = salarios$NIVEL, col = "skyblue",
        xlab = "categorias", ylab = "salários R$", main = "Gráfico de Barras")

# Adicionar legenda
legend("topright", # Posição da legenda
       legend = c("A:Rico", "B:Classe Média", "C: Pobre"),
       cex = 0.8) # Rótulos da legenda
```

3.4 Medidas de Centralidade-GRÁFICOS

PIE/PIZZA

Visualiza dados categóricos

```
salarios<-read_excel('salarios.xlsx',4)
pie(salarios$QUANTIDADE)

# vetor de cores
cores <- c("skyblue", "orange", "purple")

dados <- salarios$QUANTIDADE # Suponha que esses sejam os dados para "Rico",
# "Classe Média" e "Pobre"

# Criar gráfico de pizza
pie(dados, labels = c("55%", "15%", "30%"), col = cores,
    main = "Gráfico de Pizza", radius = 1)

# Adicionar legenda
Legend("topright", # Posição da legenda
       legend = c("Pobre", "Rico", "Classe Média"),
       fill = cores,
       cex = 0.6)
```

3.4 Medidas de Centralidade-GRÁFICOS

BOXPLOT

Visualizar a distribuição de dados numéricos, identificar outliers, avaliar assimetria, comparar distribuições

```
salarios<-read_excel('salarios.xlsx',3)

genero<- salarios$GENERO

# Converter a variável GÊNERO em um fator
salarios$GENERO <- factor(salarios$GENERO)

#Criar Boxplot

boxplot(RENDAMENSAL ~ GÊNERO, data = salarios, xlab = "Gênero", ylab = "Salário R$",
        main = "Distribuição dos salários por Gênero")
```

Referências

- Aguado, S. C. (2023). *Estatística e métodos quantitativos aplicados a finanças*. Editora Senac São Paulo.
- Asth, R. (2024). *Variância e desvio padrão: O que são, fórmulas, como calcular e exercícios*. Toda Matéria. <https://www.todamateria.com.br/variancia-e-desvio-padroao/>
- Beneti, M. (2011). *Estatística Básica*. Clube de Autores.
- Carvalho, C. de. (2024). *Introdução ao R*. <https://www.est.ufmg.br/~cristianocs/Pacotes2021/Intro.html#3>
- Castañeda, D. F. N. (2016). *Estatística Não Paramétrica*. Clube de Autores.
- Chein, F. (2019). *Introdução aos modelos de regressão linear: Um passo inicial para compreensão da econometria como uma ferramenta de avaliação de políticas públicas* /. Enap.
- Debastiani, V. J. (2020). *Introdução ao R*. https://vanderleidebastiani.github.io/tutoriais/Introducao_ao_R.html#no%C3%A7%C3%A5es_b%C3%A1sicas
- ENEM, 2024. ([s.d.]). *Matrizes: Prateleiras matemáticas / Curso Enem Play / Guia do Estudante*. Recuperado 19 de abril de 2024, de <https://guiadoestudante.abril.com.br/curso-enem/matrizes-prateleiras-matematicas>
- Georgiev, G. (2020, dezembro 9). *The p value – definition and interpretation of p-values in statistics*. GIGAcalculator Articles. <https://www.gigacalculator.com/articles/p-value-definition-and-interpretation-in-statistics/>

- Hair, J. F., Black, W. C., Babin, B. J., Anderson, R. E., & Tatham, R. L. (2009). *Análise multivariada de dados—6ed.* Bookman Editora.
- HCODE. (2024). *Qual a diferença entre linguagem compilada, interpretada e JIT (Just in Time)?* Hcode. <https://hcode.com.br/blog/qual-a-diferenca-entre-linguagem-compilada-interpretada-e-jit-just-in-time>
- Kopczewska, K. (2020). *Applied Spatial Statistics and Econometrics: Data Analysis in R.* Routledge.
- Olivoto, T. (2024). *Capítulo 1 Introdução ao ambiente R / Software R para avaliação de dados experimentais.* <https://tiagoolivoto.github.io/e-bookr/intro.html>
- Piegorsch, W. W., Levine, R. A., Zhang, H. H., & Lee, T. C. M. (2022). *Computational Statistics in Data Science.* John Wiley & Sons.
- Reis, E. A., & Reis, I. A. (2002). *Análise Descritiva de Dados. Relatório Técnico do Departamento de Estatística da UFMG.* www.est.ufmg.br
- Rosa, D. (2021, dezembro 20). *Linguagens de programação interpretadas x compiladas: Qual é a diferença?* freeCodeCamp.org. <https://www.freecodecamp.org/portuguese/news/linguagens-de-programacao-interpretadas-x-compiladas-qual-e-a-diferenca/>
- Santos, M. (Diretor). (2024). *Introdução a Linguagem R / R para iniciantes / O que de fato é a Linguagem R e como aprender?* https://www.youtube.com/watch?v=jTMOuafD_4M
- Silvestre, A. ([s.d.]). *Analise de Dados e Estatistica Descritiva.* Escolar Editora.
- UFRGS (Diretor). (2018, agosto 14). *Erros Tipo 1 (Alfa) e Tipo 2 (Beta)—Monitoria de Epidemiologia FAMED.* <https://www.youtube.com/watch?app=desktop&v=5jyi2kiIQJ0>

Para citações do trabalho:

Fonseca-Medrano, M. (2024, maio). Estatística Descritiva no Software R – Ciência de Dados. *I Seminário de Extensão do Programa Digital da UFMS*, on-line. Cidade Universitária, MS: Graduação em Ciência de Dados.



Obrigada pela Participação!

Dra. Magaly del Carmen Fonseca Medrano

E-mail: magaly.fonseca@ufms.br
fonsecatolke@gmail.com

